

仅基于正常数据的闭环非线性系统未知故障检测与结构化隔离：受保护 Koopman-T-S 正常参考方法

匿名作者

摘要—本文研究闭环非线性系统在仅有正常运行数据、没有故障样本、故障方向和故障作用模型条件下的未知故障检测与结构化隔离。核心困难在于，测量数据不仅用于形成检测残差，还常被用于更新学习状态和 T-S 调度权重；异常发生后，若正常参考模型继续吸收新测量，其轨迹可能跟随异常系统变化，导致故障响应减弱。本文提出受保护的 Koopman-Takagi-Sugeno (T-S) 正常参考方法。数据编码状态持续由严格过去的输入输出历史计算，用于描述实际系统；正常参考状态仅由经延迟确认的正常起点初始化，随后在检测时间窗内依据冻结的 Koopman-T-S 模型和已知控制指令自由递推。为避免训练和在线阶段采用不同残差定义，本文构造带起始时刻的统一多步残差，并证明其等于在线一步模型误差经过非线性学习动力学传播后的累积。利用包含规则权重变化项的完整 Jacobian，进一步给出输入和调度区域相关的有限时间正常误差上界、可靠预测长度以及延迟确认起点不被检测前异常污染的条件。检测阶段联合使用当前输出一致性、短时间滚动预测和长期受保护参考三类残差。本文证明，在异常方向完全未知时，任何严格降维投影都存在不可见异常方向；因此采用输入和运行区域条件下的全维联合归一化、多时间尺度统计量及正常数据分位阈值。隔离阶段不对故障求导，而是利用正常数据训练的传感器屏蔽预测和正常模型相对于控制输入的有限时间响应空间，将异常分为特定传感器异常、可由执行器偏差解释的异常以及不能由输入通道解释的过程侧异常，并给出多执行器通道可分条件和执行器/过程异常不可唯一分离的边界。由此形成从正常模型训练、参考更新、检测、隔离到恢复重置的完整理论与算法框架。

关键词—故障检测与隔离, Koopman 算子, Takagi-Sugeno 模糊系统, 闭环非线性系统, 仅正常数据学习, 多步预测, 动态阈值。

I. 引言

复杂工业系统往往缺少适用于全工况的精确机理模型，利用正常运行数据学习动态预测器并根据预测偏差进行故障检测，已经成为非线性故障诊断的重要路线。Koopman 方法通过学习升维坐标，把非线性动态近似表示为线性、双线性或随工况变化的线性模型，从而能够在保留数据驱动特性的同时使用系统理论中的残差分析工具 [2]–[4]。已有研究已经将 Koopman 模型用于非线性系统的几何故障检测、执行器故障诊断、传感器故障隔离和奇偶空间残差设计 [5]–[8]。

T-S 模糊模型则通过归一化规则权重组合多个局部线性模型。针对调度变量不可直接测量的问题，已有研究通常把真实规则权重与估计规则权重之间的差异作为有界不确定性，并通过 Lyapunov 函数、线性矩阵不等式或未知输入观测器建立状态估计与故障诊断条件 [9]–[11]。这些工作通常具有明确的解析模型和故障通道。对于只从正常数据学习的闭环模型，仍存在一个不同的结构问题：同一测量信号既用于产生异常信息，也用于编码学习状态和更新调度权重。如果检测器持续使用新测量校正正常参考轨迹，参考模型可能跟随异常系统共同变化，使原本应当出现的轨迹差异被部分吸收。

本文考虑更严格的数据条件：训练时只有正常输入输出序列，不知道故障类型、作用位置、方向、幅值和时间形式，也不存在可对未知故障求导的机理模型。因此，本文不构造故障基，不使用故障数据训练分类器，也不以给定故障方向的最小增益作为设计目标。需要解决的问题是：在异常类型完全未知时，如何阻止新到测量更新正常参考，同时控制自由预测产生的正常漂移；如何在不丢弃未知异常方向的情况下构造检测统计量；以及能够仅依据正常模型结构把异常隔离到什么程度。

本文的创新集中为三点，而不是多个相互独立的方法叠加。

1) 受保护正常参考与统一残差传播理论。本文将数据编码状态和正常参考状态分开：前者持续读取实际系统，后者仅由经延迟确认的正常起点初始化，并在检测时间窗内不再接受测量校正。提出带起始时刻的统一多步残差，使正常多步训练、短时间滚动监测和长期受保护监测使用同一个数学对象。本文给出不依赖故障模型的精确非线性传播式，并推导延迟确认起点不被检测前异常污染的条件。

2) Koopman-T-S 自由预测的有限时间分析与训练设计。本文推导包含规则权重变化项的完整状态和输入 Jacobian，建立输入轨迹、规则区域和参考持续时间相关的正常误差上界及可靠预测长度。该结果直接说明为什么一步训练不足、为什么多步训练必须采用自由递推，以及为什么动态阈值必须显式考虑输入和参考轨迹持续时间。

3) 仅依赖正常数据的全维检测与结构化隔离。本文证明，在没有异常方向先验时，任意严格降维都存在完全不可见的异常方向，并据此构造全维联合归一化和多时间尺度检测统计量。利用传感器屏蔽预测以及正常模型对输入的有限时间响应空间，进一步给出传感器通道隔离、执行器偏差的等效解释、过程侧剩余成分以及多执行器可分条件，同时明确不能由现有信息唯一分离的情形。

本文所称的结构化隔离，是判断哪一种正常关系被破坏，而不是在输入输出效果相同且没有任何故障先验时强行给出唯一物理部件名称。

II. 相关工作与研究缺口

A. Koopman 数据驱动故障诊断

现有 Koopman 故障诊断方法通常先由正常或正常/故障混合数据学习升维模型，再在学习空间中应用几何不变子空间、奇偶关系或残差分类方法 [5]–[8]。这些方法证明了 Koopman 表示对非线性故障诊断的价值，但多数方法在在线阶段持续使用当前或近期数据更新状态估计，且故障隔离往往依赖已知故障通道、传感器结构或特定几何条件。本文关注的不是再次构造一个 Koopman 残差，而是

正常参考轨迹在闭环检测过程中是否会吸收异常测量，以及如何在仅正常数据条件下控制这一问题。

B. T-S 不可测调度变量与模糊观测器

不可测调度变量条件下的 T-S 观测器通常通过状态估计值计算规则权重，并把权重不匹配纳入稳定性条件 [9]–[11]。这类方法主要回答估计误差是否收敛。本文的目标不同：检测器需要保留异常引起的差异，过强的测量校正虽然可能改善状态跟踪，却可能降低异常可见性。本文不设计故障观测器增益，而是把“读取实际系统”和“生成正常参照”分为两条支路。

C. 正常数据检测与动态阈值

Mahalanobis 距离、广义似然比和变化检测是未知异常检测的经典工具 [12], [15], [16]。Conformal calibration 能够利用独立正常数据给出有限样本分位覆盖；针对时间序列，还需要考虑数据块依赖和顺序校准 [17]–[19]。本文的重点不是提出新的通用校准算法，而是构造与闭环输入、T-S 运行区域和参考持续时间一致的联合残差，并证明在异常方向未知时不应先做严格降维。

III. 问题定义与正常 KOOPMAN-T-S 模型

A. 闭环对象与已知控制指令

记 $u_k \in \mathbb{R}^{n_u}$ 为控制器发出并可可信记录的控制指令， u_k^a 为实际作用到对象上的输入。系统写为

$$u_k^a = u_k + d_k^a, \quad (1)$$

$$x_{k+1} = f_0(x_k, u_k^a, \xi_k) + d_k^p + w_k, \quad (2)$$

$$y_k = g_0(x_k, u_k^a, \xi_k) + d_k^s + v_k, \quad (3)$$

其中 ξ_k 为外生工况， d_k^a, d_k^p, d_k^s 分别表示执行器侧、过程侧和传感器侧的未知异常作用。本文不假定这些量满足已知方向、已知动态或有限维时间基。正常参考模型使用已知指令 u_k 。若存在可信的实际输入测量，可额外使用 $u_k^a - u_k$ 作为直接执行器残差，但本文不依赖这一测量。

为解释闭环输入的作用，定义在同一已实现指令序列下的健康对照系统

$$x_{k+1}^0 = f_0(x_k^0, u_k, \xi_k). \quad (4)$$

命题 1 (同一控制指令条件下的闭环比较). 即使 u_k 由包含异常测量的闭环控制器产生，只要检测器使用实际记录的同时指令序列对健康对照轨迹进行条件预测，实际轨迹与健康对照轨迹的差异方程不需要控制器相对于测量的导数。异常通过执行器实际输入偏差 d_k^a 、过程异常 d_k^p 和测量异常 d_k^s 进入，而控制器对异常的反馈反应作为两条轨迹共有的已知运行条件处理。

证明. 条件于已经实现的 u_k ，将式 (4) 从式 (2) 中相减即可。控制器如何由过去测量生成该数值不再出现在条件差异方程中。□

B. 严格过去编码与模糊 Koopman 模型

定义长度为 ℓ_h 的严格过去历史

$$H_k^- = \{u_{k-\ell_h:k-1}, y_{k-\ell_h:k-1}, \xi_{k-\ell_h:k}\}. \quad (5)$$

数据编码状态为

$$z_k^E = E_\theta(H_k^-) \in \mathbb{R}^{n_z}. \quad (6)$$

表 I
主要符号

符号	含义
z_k^E	严格过去历史编码得到的数据状态
$\hat{z}_{k s}$	从时刻 s 起自由递推到 k 的正常预测
z_k^0	从最近安全确认起点递推的受保护参考
$e_{k s}^z$	带起点的统一多步状态残差
r_k^y, r_k^S, r_k^L	输出、短时间和长期残差
a_k	受保护参考持续时间
A_k^z, B_k^u	正常模型对状态和控制指令的完整 Jacobian

它是根据历史输入输出重构的学习坐标，不被解释为可直接测量的真实物理状态。

调度网络和第 i 条规则权重为

$$\rho_k = P_\eta(z_k, u_k, \xi_k), \quad (7)$$

$$h_i(\rho) = \frac{\exp s_i(\rho)}{\sum_{j=1}^{n_r} \exp s_j(\rho)}, \quad \sum_i h_i = 1. \quad (8)$$

正常学习动力学和输出解码器分别为

$$F_\Theta(z, u, \xi) = \sum_{i=1}^{n_r} h_i(P_\eta(z, u, \xi))(A_i z + B_i u + b_i), \quad (9)$$

$$G_\Theta(z, u) = C_z z + D_z u. \quad (10)$$

所有参数只用正常数据学习，并在在线检测前冻结。

假设 1 (数据条件). 训练阶段只有正常轨迹 (u_k, y_k, ξ_k) ，不存在故障样本、故障方向、故障基以及可微的故障到输出模型。 u_k 和 ξ_k 可可信记录。

假设 2 (正常区域光滑性). F_Θ 在需要分析的紧致正常运行区域 $\mathcal{D}$ 内连续可微；用于归一化的条件协方差经正则化后正定。

IV. 受保护正常参考与统一多步残差

A. 统一的起点索引残差

对任意起点 $s \leq k$ ，令

$$\hat{z}_{s|s} = z_s^E, \quad (11)$$

并在后续时间完全自由递推

$$\hat{z}_{t+1|s} = F_\Theta(\hat{z}_{t|s}, u_t, \xi_t), \quad t = s, \dots, k-1. \quad (12)$$

定义统一多步状态残差

$$e_{k|s}^z = z_k^E - \hat{z}_{k|s}. \quad (13)$$

训练阶段随机选择正常起点和预测长度；在线阶段采用两个特殊起点：

$$r_k^S = e_{k|k-L_s}^z, \quad \text{短时间滚动残差}, \quad (14)$$

$$r_k^L = e_{k|s_k^0}^z, \quad \text{长期受保护残差}, \quad (15)$$

其中 s_k^0 为最近一次被确认可安全使用的正常起点， $z_k^0 := \hat{z}_{k|s_k^0}$ 。因此，训练和测试阶段不存在两种不同的 e^z ；它们只是在式 (13) 中选择不同的 s 。

B. 延迟确认的安全起点

仅在统计量超过阈值后冻结参考仍可能太晚，因为故障在告警前已经进入编码历史。为此，本文采用延迟确认：时刻 s 的编码状态先作为候选起点，只有在未来 D_c 个采样内所有检测统计量均处于正常范围，并且该段没有预警或告警时，才被确认为安全起点。在线受保护参考始终从最新已确认起点自由递推。

命题 2 (检测前污染的延迟阻断). 设异常从时刻 τ 开始，检测器最迟在 $\tau + D_a$ 进入告警，且起点确认延迟满足 $D_c \geq D_a$ 。则任何首次包含异常测量的候选编码状态都不会在告警前被确认为安全起点；告警发生时删除尚未确认的候选队列即可阻止这些状态进入受保护参考。

证明. 由于编码器使用严格过去历史，最早可能包含异常测量的候选状态为 $z_{\tau+1}^E$ 。其最早确认时刻为 $\tau + 1 + D_c > \tau + D_a$ ，因此在告警并清空候选队列前不会生效。□

若异常在 τ_e 结束，则只有 $s \geq \tau_e + \ell_h + 1$ 的编码窗口不再包含异常测量。恢复阶段还需经过 D_c 个连续正常确认样本，才能重新接收新起点。

C. 无需故障模型的精确传播

定义在线可计算的一步正常模型误差

$$\nu_k^E = z_{k+1}^E - F_\Theta(z_k^E, u_k, \xi_k). \quad (16)$$

定理 1 (统一残差的精确非线性递推). 对任意起点 s 和 $k \geq s$ ，有

$$e_{k+1|s}^z = \bar{A}_{k|s} e_{k|s}^z + \nu_k^E, \quad (17)$$

其中

$$\bar{A}_{k|s} = \int_0^1 J_z F_\Theta(\hat{z}_{k|s} + \tau e_{k|s}^z, u_k, \xi_k) d\tau. \quad (18)$$

由于 $e_{s|s}^z = 0$ ，进一步有

$$e_{k|s}^z = \sum_{j=s}^{k-1} \bar{\Phi}(k, j+1) \nu_j^E, \quad (19)$$

其中 $\bar{\Phi}(k, j+1) = \bar{A}_{k-1|s} \cdots \bar{A}_{j+1|s}$ 。

证明. 在 $z_{k+1}^E - \hat{z}_{k+1|s}$ 中加减 $F_\Theta(z_k^E, u_k, \xi_k)$ ，再对两点间的 F_Θ 使用积分形式的中值公式，得到式 (17)。递归展开得到式 (19)。□

该结论不需要知道异常是什么。突发异常首先使 ν_k^E 变化；持续但较弱的异常经过正常模型传播，在 r^S 和 r^L 中累积。受保护参考保证比较中的正常轨迹不会因新测量而同步变化。

命题 3 (异常测量的有限历史影响). 若某传感器异常只发生在 $[\tau_1, \tau_2]$ ，则其测量值能够直接进入 z_k^E 的时间范围为

$$k \in [\tau_1 + 1, \tau_2 + \ell_h]. \quad (20)$$

V. 正常多步训练与有限时间误差分析

A. Koopman-T-S 映射的完整 Jacobian

记

$$v_i(z, u) = A_i z + B_i u + b_i, \quad V = [v_1, \dots, v_{n_r}]. \quad (21)$$

正常模型对状态和控制指令的完整 Jacobian 分别为

$$A_k^z := J_z F_\Theta = \sum_i h_i A_i + V J_{h,\rho} J_{P,z}, \quad (22)$$

$$B_k^u := J_u F_\Theta = \sum_i h_i B_i + V J_{h,\rho} J_{P,u}. \quad (23)$$

对 softmax 规则权重，

$$J_{h,\rho} = (\text{diag}(h) - hh^\top) J_s(\rho). \quad (24)$$

式 (22) 的第二项表示状态变化通过调度网络改变规则权重后引起的附加动态变化。仅检查局部矩阵 A_i 的稳定性不足以保证自由预测可靠。式 (23) 则给出健康模型中控制输入对学习状态的完整局部影响，是后续执行器结构化隔离的依据。

B. 有限时间正常误差上界与可靠预测长度

定理 2 (正常自由预测误差上界). 若正常运行时，在两条轨迹之间的线段上满足

$$\|J_z F_\Theta(z, u_k, \xi_k)\|_2 \leq \lambda_k, \quad \left\| \nu_k^{E,0} \right\|_2 \leq \varepsilon_k, \quad (25)$$

则从正常起点 s 开始的残差满足

$$\left\| e_{s+\ell|s}^{z,0} \right\|_2 \leq \sum_{j=0}^{\ell-1} \left(\prod_{p=j+1}^{\ell-1} \lambda_{s+p} \right) \varepsilon_{s+j}. \quad (26)$$

若 $\lambda_k \leq \lambda$ 且 $\varepsilon_k \leq \varepsilon$ ，则当 $\lambda < 1$ 、 $\lambda = 1$ 和 $\lambda > 1$ 时，上界分别为 $\varepsilon(1 - \lambda^\ell)/(1 - \lambda)$ 、 $\ell\varepsilon$ 和 $\varepsilon(\lambda^\ell - 1)/(\lambda - 1)$ 。

证明. 对式 (17) 取范数，使用 Jacobian 范数上界并递归展开。□

定义输入和调度轨迹条件下的理论上界

$$\mathcal{B}_s(\ell) = \sum_{j=0}^{\ell-1} \left(\prod_{p=j+1}^{\ell-1} \lambda_{s+p} \right) \varepsilon_{s+j}. \quad (27)$$

给定允许的正常参考误差 δ_z ，可靠预测长度定义为

$$N_{\text{rel}}(s) = \max\{\ell : \mathcal{B}_s(\ell) \leq \delta_z\}. \quad (28)$$

实际实现中， λ_k 和 ε_k 可以由正常验证数据在不同输入和规则区域中估计。若受保护参考持续时间超过已验证的可靠范围，算法应扩大阈值、切换到更保守的统计模型或停止给出保证。




图 1. 受保护 Koopman-T-S 正常参考框架。测量用于描述实际系统并形成残差，但新测量不直接更新已经确认的正常参考。

C. 与在线自由递推一致的训练

在正常轨迹中随机选取起点 s 和预测长度，按式 (12) 完全自由递推。训练损失包括

$$\mathcal{L}_{\text{one}} = \sum_k \|z_{k+1}^E - F_{\Theta}(z_k^E, u_k, \xi_k)\|_{P_1}^2, \quad (29)$$

$$\mathcal{L}_z^{\text{fr}} = \sum_{j=1}^{N_{\max}} w_j^z \|z_{s+j}^E - \hat{z}_{s+j|s}\|_{P_z}^2, \quad (30)$$

$$\mathcal{L}_y^{\text{fr}} = \sum_{j=1}^{N_{\max}} w_j^y \|y_{s+j} - G_{\Theta}(\hat{z}_{s+j|s}, u_{s+j})\|_{P_y}^2. \quad (31)$$

总目标写为

$$\mathcal{L} = \mathcal{L}_{\text{enc}} + \beta_1 \mathcal{L}_{\text{one}} + \beta_z \mathcal{L}_z^{\text{fr}} + \beta_y \mathcal{L}_y^{\text{fr}} + \beta_m \mathcal{L}_{\text{mask}}. \quad (32)$$

自由多步项不能采用每一步重新输入真实 z_{s+j}^E 的教师强制方式，否则训练时不会暴露在线自由递推中的误差累积。主训练目标不需要对 Jacobian 范数求梯度，因此不引入二阶反向传播；完整 Jacobian 在模型冻结后通过自动微分计算，用于理论分析和结构化隔离。

VI. 联合残差与动态检测统计量

A. 三类互补残差

当前输出一致性残差为

$$r_k^y = y_k - G_{\Theta}(z_k^E, u_k). \quad (33)$$

联合残差定义为

$$R_k = \text{col}(r_k^y, r_k^S, r_k^L). \quad (34)$$

相对于受保护参考的输出预测误差为

$$r_k^{y,0} = y_k - G_{\Theta}(z_k^0, u_k) = r_k^y + C_z r_k^L. \quad (35)$$

命题 4 (残差信息等价). 变换

$$\begin{bmatrix} r_k^L \\ r_k^{y,0} \end{bmatrix} = \begin{bmatrix} I & 0 \\ C_z & I \end{bmatrix} \begin{bmatrix} r_k^L \\ r_k^y \end{bmatrix} \quad (36)$$

可逆。因此，联合使用 (r_k^y, r_k^L) 与使用 $(r_k^{y,0}, r_k^L)$ 包含相同信息。 r_k^S 用于突出最近一段时间的动力学偏差， r_k^L 用于积累相对于最后安全状态的长期变化。

不同异常的典型传播规律见表 II。传感器异常首先直接进入 r^y ，随后经编码历史进入 r^S 和 r^L ；执行器和过程异常通常首先表现为动力学偏差，再在长期参考残差中累积。

B. 输入和运行区域条件下的联合归一化

定义运行上下文

$$\zeta_k = \text{col}(z_k^0, \bar{u}_{k,L_u}, \Delta u_k, \xi_k, \bar{h}_{k,L_h}^0, a_k), \quad (37)$$

其中 $\bar{u}_{k,L_u}$ 表示近期输入摘要， $\bar{h}_{k,L_h}^0$ 表示受保护参考轨迹上的规则权重摘要， $a_k = k - s_k^0$ 为参考持续时间。根据正常数据预先划分模糊运行区域 c 和参考持续时间组 a ，估计

$$\mu_{c,a} = \mathbb{E}[R_k | c, a], \quad \Sigma_{c,a} = \text{cov}(R_k | c, a) + \epsilon I. \quad (38)$$

若多个局部统计模型按规则权重组合，则完整协方差应为

$$\Sigma(\zeta) = \sum_i h_i^0 [\Sigma_i + (\mu_i - \mu)(\mu_i - \mu)^{\top}] + \epsilon I, \quad (39)$$

而不是仅对局部协方差作线性加权。

令 $L_k L_k^{\top} = \Sigma_k$ ，白化残差为

$$w_k = L_k^{-1}(R_k - \mu_k). \quad (40)$$

按 (r^y, r^S, r^L) 顺序对协方差作分块 Cholesky 分解，可写成

$$T_k^G = \|w_k\|^2 = T_k^Y + T_k^S + T_k^L, \quad (41)$$

其中每一项是给定前面残差后的条件新增量，可用于解释异常首先出现在哪条关系中。

C. 未知异常方向时不应严格降维

定理 3 (严格降维必然存在不可见方向). 设正常白化残差 $w \sim \mathcal{N}(0, I_m)$ 。对任意 $Q \in \mathbb{R}^{q \times m}$ 且 $q < m$ ，均存在 $0 \neq \delta \in \mathbb{R}^m$ ，使

$$H_0 : w \sim \mathcal{N}(0, I_m), \quad H_1 : w \sim \mathcal{N}(\delta, I_m)$$

经过投影 Q 后具有完全相同的分布。

证明. 取任意 $0 \neq \delta \in \text{Null}(Q)$ ，则两种假设下 Qw 的均值均为零，协方差均为 $QQ^{\top}$ 。□

因此，在没有故障方向先验时，不能为了优化给定方向而先设计低维子空间。全维联合残差保留所有正常模型可观测的异常方向。

定理 4 (未知均值变化的广义似然比统计量). 在 $H_0 : w \sim \mathcal{N}(0, I_m)$ 与 $H_1 : w \sim \mathcal{N}(\delta, I_m)$ 、 $\delta \neq 0$ 未知的条件下，广义似然比检验与

$$T_k^G = \|w_k\|^2 = (R_k - \mu_k)^{\top} \Sigma_k^{-1} (R_k - \mu_k) \quad (42)$$

单调等价。

证明. 在备择假设下对 δ 最大化似然，得到 $\hat{\delta} = w_k$ ，代回后似然比与 $\exp(\|w_k\|^2 / 2)$ 单调等价。□

表 II
不同异常的典型残差传播规律

异常类型	最先变化的量	后续传播	仅正常数据下可作出的结构判断
传感器异常	当前 r^y 直接变化	进入编码历史后影响 r^S, r^L	可利用屏蔽该传感器历史的预测残差进行通道级判断
执行器异常	实际输入与指令不一致, 短时间动力学残差变化	长期参考残差逐步累积	可判断异常是否主要位于健康输入响应空间内
过程异常	短时间动力学残差沿一般方向变化	长期参考残差逐步累积	输入响应空间外的部分不能由单纯执行器偏差解释
正常控制指令变化	实际健康系统与正常参考共同使用同一 u_k	正常模型正确时不应形成持续异常残差	作为阈值条件变量, 而不是对象故障

D. 多时间尺度统计量与动态阈值

针对突发、持续偏置和方差增加型异常, 定义

$$T_k^{\text{inst}} = \|w_k\|^2, \quad (43)$$

$$T_{k,N}^{\text{mean}} = \left\| N^{-1/2} \sum_{j=k-N+1}^k w_j \right\|^2, \quad (44)$$

$$T_{k,N}^{\text{energy}} = \sum_{j=k-N+1}^k \|w_j\|^2. \quad (45)$$

对有限时间尺度集合 $\mathcal{N}$, 令

$$T_k^{\text{max}} = \max \left\{ \psi_0(T_k^{\text{inst}}), \max_{N \in \mathcal{N}} \psi_N^m(T_{k,N}^{\text{mean}}), \max_{N \in \mathcal{N}} \psi_N^e(T_{k,N}^{\text{energy}}) \right\}, \quad (46)$$

其中 ψ 根据正常数据把不同统计量映射到统一分位尺度。最终阈值必须直接对最大统计量校准, 不能把多个单独显著性水平直接并列使用。

在每个运行区域 c 和参考持续时间组 a 中, 对 $M_{c,a}$ 个独立运行批次或不重叠正常校准块计算 T_j^{max} , 取

$$q_{c,a,1-\alpha} = T_{(\lceil (M_{c,a}+1)(1-\alpha) \rceil)}^{\text{max}}. \quad (47)$$

在线动态阈值为 $J_{\text{th},k} = q_{c_k,a_k,1-\alpha}$ 。控制输入通过条件均值、条件协方差和运行区域选择进入阈值。

定理 5 (运行区域内的有限样本正常覆盖). 若同一 (c, a) 区域内的正常校准块与未来正常块可交换, 则

$$\mathbb{P}\{T_k^{\text{max}} \leq q_{c,a,1-\alpha} \mid c, a\} \geq 1 - \alpha. \quad (48)$$

该结论是预定义运行区域内的边际覆盖。对强时间相关数据, 应采用独立运行批次、不重叠块或专门的顺序校准方法 [18], [19]。若当前输入和规则轨迹超出正常覆盖范围, 算法应输出“当前范围内不能给出统计保证”。

VII. 仅依赖正常数据的结构化隔离

A. 传感器屏蔽预测

为避免持续传感器异常通过自身历史进入编码器, 训练一个共享带掩码编码器。令 $M^{(-j)}$ 屏蔽第 j 个传感器的全部历史, 定义

$$z_k^{E,-j} = E_{\vartheta}(H_k^-, M^{(-j)}), \quad (49)$$

以及传感器隔离残差

$$r_{j,k}^{\text{sen}} = y_{j,k} - [G_{\Theta}(z_k^{E,-j}, u_k)]_j. \quad (50)$$

训练时在正常数据上随机屏蔽不同传感器并重构当前输出, 形成式 (32) 中的 $\mathcal{L}_{\text{mask}}$

命题 5 (屏蔽残差对本通道异常的直接响应). 若第 j 个传感器的异常以加性形式进入当前测量, 并且屏蔽预测器不使用该传感器的当前值及历史值, 则条件于其他测量历史、 u_k 和 ξ_k , 有

$$r_{j,k}^{\text{sen}} = r_{j,k}^{\text{sen},0} + d_{j,k}^s. \quad (51)$$

因此持续异常不会通过该传感器自身历史被预测器直接吸收。

可隔离性的前提是去掉第 j 个传感器后, 其余正常输入输出仍包含足够信息预测 $y_{j,k}$; 否则应报告该通道冗余不足。

B. 执行器可解释成分与过程侧剩余成分

沿受保护参考轨迹使用式 (22)–(23) 构造长度 L 的有限时间输入响应矩阵

$$\mathcal{G}_{u,k,L} = \begin{bmatrix} B_{k-L}^u & 0 & \cdots & 0 \\ A_{k-L+1}^z B_{k-L}^u & B_{k-L+1}^u & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ \Phi_{k,k-L+1} B_{k-L}^u & \Phi_{k,k-L+2} B_{k-L+1}^u & \cdots & B_{k-1}^u \end{bmatrix}, \quad (52)$$

其中 $\Phi_{k,j} = A_{k-1}^z \cdots A_j^z$ 。将相应短时间学习状态偏差堆叠为 $\mathbf{e}_{k,L}$, 并按正常协方差归一化:

$$\tilde{\mathbf{e}} = \Sigma_e^{-1/2}(\mathbf{e}_{k,L} - \mu_e), \quad \tilde{G} = \Sigma_e^{-1/2} \mathcal{G}_{u,k,L}. \quad (53)$$

定义投影

$$P_u = \tilde{G}(\tilde{G}^\top \tilde{G})^\dagger \tilde{G}^\top, \quad (54)$$

以及

$$T_k^A = \|P_u \tilde{\mathbf{e}}\|^2, \quad (55)$$

$$T_k^P = \|(I - P_u) \tilde{\mathbf{e}}\|^2. \quad (56)$$

命题 6 (最佳等效输入解释与正交剩余). 等效输入偏差

$$\hat{\mathbf{d}}_{k,L}^a = (\tilde{G}^\top \tilde{G})^\dagger \tilde{G}^\top \tilde{\mathbf{e}} \quad (57)$$

是最小化 $\|\tilde{\mathbf{e}} - \tilde{G} \hat{\mathbf{d}}\|^2$ 的最小范数解, 且

$$\|\tilde{\mathbf{e}}\|^2 = T_k^A + T_k^P. \quad (58)$$

T_k^A 表示可由健康输入通道中的未知偏差解释的异常能量, T_k^P 表示任何输入偏差都无法解释的剩余能量。

$\hat{\mathbf{d}}_{k,L}^a$ 只能称为等效输入偏差。若过程异常的输入输出作用也位于 $\text{Range}(\mathcal{G}_{u,k,L})$, 则二者无法唯一分离; 只有正交剩余可以确定为不符合单纯执行器偏差解释。

算法 1 仅正常数据的离线设计

输入：正常轨迹 (u, y, ξ)

- 1: 按式 (32) 训练编码器、调度网络、局部 Koopman 模型和输出解码器；所有多项采用自由递推。
- 2: 在正常数据上随机屏蔽传感器历史，训练共享带掩码编码器。
- 3: 按延迟确认起点和在线参考更新规则回放正常数据，生成不同输入区域、短时间长度和参考持续时间下的 r^y, r^S, r^L 。
- 4: 估计条件均值、条件协方差、可靠预测长度及适用范围。
- 5: 用独立正常块校准多时间尺度最大统计量和各条件新增量阈值。
- 6: 通过自动微分计算 A_k^z, B_k^u ，构造各运行区域的有限时间输入响应空间和执行器可分裕度。
- 7: 冻结模型、统计参数、阈值和范围检查规则。

C. 多执行器通道的可分条件

把输入响应矩阵按执行器通道分块：

$$\tilde{G} = [\tilde{G}_1, \dots, \tilde{G}_{n_u}]. \quad (59)$$

令 P_{-j} 为除第 j 个执行器外其他通道响应空间的投影，定义通道可分裕度

$$\gamma_j = \sigma_{\min}((I - P_{-j})\tilde{G}_j). \quad (60)$$

定理 6 (执行器通道有限时间可分条件). 若 $\gamma_j > 0$ ，则第 j 个执行器在所选时间窗内的任意非零等效偏差序列都含有不能由其他执行器通道复制的残差分量，因此该通道在一阶正常模型下可与其他执行器隔离。若 $\gamma_j = 0$ ，则至少存在一个非零第 j 通道偏差序列，其残差作用可由其他执行器通道完全复制，无法保证唯一隔离。

证明. $\gamma_j > 0$ 等价于 $(I - P_{-j})\tilde{G}_j$ 满列秩，因而任意非零系数向量经该映射后非零。 $\gamma_j = 0$ 时存在非零向量位于其零空间，对应响应落入其他通道的张成空间。□

D. 分层隔离逻辑

全局统计量超过阈值后，按以下顺序判断：

- 若 T_k^Y 最先显著增加，且某个 $r_{j,k}^{\text{sen}}$ 占主导，则判断为第 j 个传感器异常；
- 若动力学异常显著、 T_k^A 高而 T_k^P 低，则判断为可由执行器偏差解释的异常，并输出等效输入偏差；
- 若 T_k^P 显著，则判断存在正常输入通道无法解释的过程侧或未建模动态异常；
- 若 T_k^A 与 T_k^P 同时显著，或通道裕度 γ_j 太小，则报告混合异常或信息不足，不强制给出唯一类别。

VIII. 完整离线与在线算法

在线高频计算包括编码器前向、两个有限长度自由递推、条件归一化和统计量更新。完整 Jacobian 和输入响应空间可按运行区域预计算或低频更新。训练、运行区域划分和阈值校准全部离线完成。

算法 2 受保护参考在线检测与结构化隔离

输入：冻结模型、候选起点队列、受保护参考和统计参数库

- 1: **for** 每个采样时刻 k **do**
- 2: 读取 u_k, y_k, ξ_k 并计算 z_k^E 。
- 3: 仅用冻结模型更新滚动预测器和受保护参考 z_k^0 。
- 4: 计算 r_k^y, r_k^S, r_k^L 和运行上下文 ζ_k 。
- 5: 若工况在覆盖范围内，计算联合白化、多时间尺度统计量和动态阈值；否则输出范围外状态并冻结候选起点。
- 6: **if** $T_k^{\max} > J_{\text{th},k}$ **then**
- 7: 进入预警/告警，清空未确认候选起点并冻结参考更新。
- 8: 计算传感器屏蔽残差、 T_k^A, T_k^P 、等效输入偏差及执行器通道得分。
- 9: 输出结构类别或“信息不足”。
- 10: **else**
- 11: 将当前编码状态加入候选队列；仅在未来 D_c 个样本均正常后确认为安全起点。
- 12: 恢复后仅当异常数据已离开长度 ℓ_h 的编码窗口并完成连续正常确认，才重新允许起点更新。
- 13: **end if**
- 14: **end for**

表 III
主要在线计算

操作	实现方式
数据编码	冻结网络一次前向
短/长期预测	两个有限长度状态递推或环形缓存
联合归一化	分区 Cholesky 预分解或低秩更新
多尺度统计	滑动和、滑动能量递推
传感器隔离	告警后按需执行带掩码前向
输入空间隔离	告警后执行小规模投影/最小二乘

IX. 理论示例与边界说明

考虑局部二维学习模型

$$z_{k+1} = A_k z_k + B_k u_k, \quad B_k = \begin{bmatrix} 1 \\ 0 \end{bmatrix}, \quad y_k = z_k + d_k^s. \quad (61)$$

编码器只使用 y_{k-1} 及更早测量。若当前第一个传感器出现偏差 $d_k^s = [b, 0]^T$ ，则 r_k^y 立即变化，而当前 z_k^E 尚未变化；下一时刻开始，该偏差进入编码历史并影响 r^S 与 r^L 。屏蔽第一个传感器历史后，其隔离残差仍以 b 为直接附加项。

执行器偏差引起的学习状态变化位于 $\text{Range}(B_k)$ 。若过程异常为 $[0, p]^T$ ，其作用位于输入响应空间的正交方向，理想情况下表现为 $T^P > 0$ 。若过程异常为 $[p, 0]^T$ ，其输入输出作用与执行器偏差完全一致，任何只使用当前输入输出的算法都不能唯一分离。这一例子说明结构化隔离既能利用正常模型中的可分信息，也必须承认信息不足的边界。

本文不能保证任何物理故障都一定可检测。若异常不改变可测输入输出、只沿正常行为集合运动，或其作用与正

常模型误差完全相同, 则不存在仅凭现有信息实现无条件检测的方法。本文能够保证的是: 受保护参考不会直接使用新到测量更新; 在已覆盖正常运行区域内, 离开正常联合残差区域的异常能够被统计量发现; 结构隔离只在相应条件可辨识时成立。

X. 结论

本文面向只有正常训练数据、没有故障方向和故障作用模型的闭环非线性系统, 提出受保护 Koopman-T-S 正常参考方法。数据编码状态负责持续描述实际系统, 正常参考状态只由延迟确认的安全起点初始化, 并在检测时间窗内依据已知控制指令和冻结模型自由递推。带起点的统一多步残差消除了训练与在线阶段的定义不一致; 精确非线性递推和完整 Jacobian 上界揭示了正常模型误差如何随输入、规则区域和参考持续时间传播。对于完全未知的异常方向, 本文证明严格降维会留下不可见方向, 并据此建立全维联合归一化、多时间尺度统计量和输入条件动态阈值。传感器屏蔽预测和正常输入响应空间进一步实现传感器通道判断、执行器等效解释和过程侧剩余分解, 同时给出多执行器可分条件及不可唯一分离的边界。该框架在不使用故障样本、不对故障求导的前提下, 形成了逻辑一致的正常模型训练、参考保护、未知故障检测、结构化隔离和安全恢复方法。

附录 A

条件新增量分解

将 $R = \text{col}(R_y, R_S, R_L)$ 及其协方差按相同顺序分块。第一项为 $\tilde{R}_y = R_y - \mu_y$ 。第二项扣除正常情况下由 R_y 可解释的部分:

$$\tilde{R}_S = R_S - \mu_S - \Sigma_{Sy} \Sigma_{yy}^{-1} (R_y - \mu_y), \quad (62)$$

其协方差为 $\Sigma_{S|y} = \Sigma_{SS} - \Sigma_{Sy} \Sigma_{yy}^{-1} \Sigma_{yS}$ 。第三项再扣除给定 (R_y, R_S) 后的条件均值。对 Σ 作分块 LDL^T 分解即可得到式 (41)。

附录 B

有限时间输入响应矩阵的推导

沿受保护正常轨迹对学习模型作一阶展开:

$$\delta z_{t+1} = A_t^z \delta z_t + B_t^u \delta u_t. \quad (63)$$

从 $\delta z_{k-L} = 0$ 开始递推并堆叠 $\delta z_{k-L+1:k}$, 得到式 (52)。这里 A_t^z 和 B_t^u 是正常模型对普通状态变量和控制指令的导数, 不涉及未知故障参数。

参考文献

- [1] T. Takagi and M. Sugeno, "Fuzzy identification of systems and its applications to modeling and control," *IEEE Trans. Syst., Man, Cybern.*, vol. SMC-15, no. 1, pp. 116–132, 1985.
- [2] S. L. Brunton, B. W. Brunton, J. L. Proctor, and J. N. Kutz, "Koopman invariant subspaces and finite linear representations of nonlinear dynamical systems for control," *PLoS ONE*, vol. 11, no. 2, Art. no. e0150171, 2016.
- [3] M. Korda and I. Mezić, "Linear predictors for nonlinear dynamical systems: Koopman operator meets model predictive control," *Automatica*, vol. 93, pp. 149–160, 2018.
- [4] B. Lusch, J. N. Kutz, and S. L. Brunton, "Deep learning for universal linear embeddings of nonlinear dynamics," *Nature Commun.*, vol. 9, Art. no. 4950, 2018.
- [5] M. Bakhtiaridoust, M. Yadegar, N. Meskin, and M. Noorizadeh, "Model-free geometric fault detection and isolation for nonlinear systems using Koopman operator," *IEEE Trans. Syst., Man, Cybern.: Syst.*, vol. 52, no. 11, pp. 7207–7218, 2022.
- [6] M. Bakhtiaridoust, M. Yadegar, and N. Meskin, "Data-driven fault detection and isolation of nonlinear systems using deep learning for Koopman operator," *ISA Trans.*, vol. 134, pp. 200–211, 2023.
- [7] M. Bakhtiaridoust, F. N. Irani, M. Yadegar, and N. Meskin, "Data-driven sensor fault detection and isolation of nonlinear systems: Deep neural-network Koopman operator," *IET Control Theory Appl.*, vol. 17, no. 2, pp. 123–132, 2023.
- [8] F. N. Irani, M. Yadegar, and N. Meskin, "Koopman-based deep iISS bilinear parity approach for data-driven fault diagnosis: Experimental demonstration using three-tank system," *Control Eng. Pract.*, vol. 142, Art. no. 105744, 2024.
- [9] D. Ichalal, B. Marx, J. Ragot, and D. Maquin, "State estimation of Takagi–Sugeno systems with unmeasurable premise variables," *IET Control Theory Appl.*, vol. 4, no. 5, pp. 897–908, 2010.
- [10] H. Ghorbel, M. Souissi, M. Chaabane, and D. Mehdi, "Observer design for fault diagnosis for the Takagi–Sugeno model with unmeasurable premise variables," in *Proc. IEEE Int. Conf. Fuzzy Syst.*, 2012, pp. 1–8.
- [11] Z. Lendek, T. M. Guerra, R. Babuška, and B. De Schutter, *Stability Analysis and Nonlinear Observer Design Using Takagi–Sugeno Fuzzy Models*. Berlin, Germany: Springer, 2010.
- [12] S. X. Ding, *Model-Based Fault Diagnosis Techniques: Design Schemes, Algorithms, and Tools*, 2nd ed. London, U.K.: Springer, 2013.
- [13] J. Gertler, "Fault detection and isolation using parity relations," *Control Eng. Pract.*, vol. 5, no. 5, pp. 653–661, 1997.
- [14] P. M. Frank, "Fault diagnosis in dynamic systems using analytical and knowledge-based redundancy: A survey and some new results," *Automatica*, vol. 26, no. 3, pp. 459–474, 1990.
- [15] M. Basseville and I. V. Nikiforov, *Detection of Abrupt Changes: Theory and Application*. Englewood Cliffs, NJ, USA: Prentice-Hall, 1993.
- [16] H. V. Poor, *An Introduction to Signal Detection and Estimation*, 2nd ed. New York, NY, USA: Springer, 1994.
- [17] V. Vovk, A. Gammernan, and G. Shafer, *Algorithmic Learning in a Random World*. New York, NY, USA: Springer, 2005.
- [18] C. Xu and Y. Xie, "Conformal prediction for time series," arXiv:2010.09107, 2021.
- [19] C. Xu and Y. Xie, "Sequential predictive conformal inference for time series," in *Proc. Int. Conf. Mach. Learn.*, 2023, pp. 38707–38727.
- [20] G. W. Stewart and J.-G. Sun, *Matrix Perturbation Theory*. Boston, MA, USA: Academic Press, 1990.
- [21] S. Boyd and L. Vandenberghe, *Convex Optimization*. Cambridge, U.K.: Cambridge Univ. Press, 2004.